

Taller 4 del Bloque 3

Redes Neuronales

Fernando Dapena Tauste · Oscar Romero Quincoces · Daniel García López

Pipeline · 16 arquitecturas · Preprocesado avanzado (FFD) · Carteras 2025
ejecutadas

01

Resultado de la competición

Matriz 4×4 de mejores MAE · Colapso universal a la media · V_in irrelevante · NN empata con lineal óptimo

02

Reflexión sobre modelos

16 arquitecturas · Δ MAE < 0.0001 entre sí · Lineal(V_in=5, 2 668 params) idéntico a NN en V_out ≥ 5d

03

Preprocesado avanzado — FFD

Diferenciación Fraccional (López de Prado) · d óptimo = 0.2 · -8.9% en V_out=1d · empeora en V_out=30d

04

Carteras 2025 — resultados reales

Buy & Hold +21.94% · Cartera NN +22.11% · Sharpe 1.186 vs 1.201 · MaxDD -11.33% vs -11.12%

23

ACTIVOS SP500

16

ARQUITECTURAS

256

ENTRENAMIENTOS

4×4

VENTANAS V_IN×V_OUT

6

SECCIONES

20 de mayo de 2026

§ 00

Pipeline de Entrenamiento — Técnicas Comunes

Configuración compartida por todos los modelos · src/utils.py · mismos hiperparámetros en los 256 entrenamientos

TABLA 0A — HIPERPARÁMETROS GLOBALES · COMPILER_MODEL()

COMPONENTE	VALOR	JUSTIFICACIÓN
Optimizador	Adam · $\text{lr} = 3 \times 10^{-4}$	Default robusto para series temporales; sin tuning del lr inicial entre modelos
Función de pérdida	MAE	Directamente interpretable en escala de retornos; menos sensible a outliers que MSE
Épocas	100 (NB 02-04) · 500 (NB 05)	Sin EarlyStopping para observar la curva completa de aprendizaje
Batch size	32 (Keras default)	Uniforme en todos los modelos para comparabilidad directa
Semilla	RANDOM_SEED = 42	Reproducibilidad de particiones y pesos iniciales

TABLA 0B — CALLBACKS · GET_CALLBACKS() + RESTORE_BEST_WEIGHTS()

CALLBACK	PARÁMETROS CLAVE	EFECTO
ReduceLROnPlateau	monitor=val_loss · factor=0.9 · patience=15 · min_lr=1e-5	Si val_loss no mejora en 15 épocas consecutivas → $\text{lr} \leftarrow \text{lr} \times 0.9$ (descenso suave hasta mínimo 10^{-5})
ModelCheckpoint	monitor=val_loss · save_best_only=True	Guarda pesos del epoch con menor val_loss. restore_best_weights() los recarga tras model.fit()
EarlyStopping	— (no usado)	Omitido deliberadamente: ModelCheckpoint ya captura el mejor estado; se prefiere ver la curva completa

SPLIT	% DEL TOTAL	DETALLE
Train	67.5 %	75% de train_full · ventanas temporalmente anteriores
Validación	22.5 %	25% de train_full · señal para ReduceLROnPlateau y ModelCheckpoint
Test	10 %	Separado antes del split train/val · nunca visto durante entrenamiento
Ventanas deslizantes	create_time_series_data	X: (N, V_in, 23) retornos pasados · y: (N, 23) media de los V_out retornos futuros

★ La val del 25% (vs. el 5% de un split simple 90/5/5) da a ReduceLROnPlateau una señal más estable, reduciendo reducciones de lr espurias por ruido en val pequeño.

NAIVE FORECAST — EVAL_MAE_NAIVE()

El naive predice el **último retorno conocido** de la ventana de entrada: $y_{pred} = X[:, -1, :]$. Es un baseline asimétrico: excelente en $V_{out}=1d$ (correlación serial de primer orden del SP500 ≈ 0 pero positiva), pero muy malo a largo plazo donde la media supera al último valor. Sirve como *cota superior de MAE* que cualquier modelo razonable debe superar.

§ 01

Resultado de la Competición

Mejor MAE test por combinación de ventanas · 16 modelos · 256 entrenamientos totales


FIG. 1 — MATRIZ 4×4 DE MEJOR MAE TEST (REDES NEURONALES)

V_IN \ V_OUT	V_OUT = 1D	V_OUT = 5D	V_OUT = 30D	V_OUT = 90D
V_in = 5d	0.0123	0.0056	0.0023	0.0013 ★ MÍN GLOBAL
V_in = 10d	0.0123	0.0056	0.0023	0.0013
V_in = 30d	0.0123	0.0056	0.0023	0.0013
V_in = 90d	0.0123	0.0056	0.0023	0.0013

REFERENCIAS COMPARATIVAS

Lineal (V_in=5)	0.0124	0.0056	0.0023	0.0013
Naive	0.0178	0.0137	0.0125	0.0122

Fig. 1. Las cuatro filas de la matriz NN son idénticas (V_in es irrelevante). El lineal óptimo (V_in=5) iguala a las NN en 3 de 4 horizontes; el naive sirve solo como cota superior.



1. V_in es completamente irrelevante

Las 4 filas de la matriz son idénticas. El modelo ignora el contexto extra porque el input es ruido blanco.

2. Colapso universal a la media

std(pred)/std(y) ≈ 0.06–0.10. Diferencias entre arquitecturas: Δ MAE < 0.0001 en 15 de 16 combinaciones.

3. Lineal(V_in=5) ≡ NN en 3/4 horizontes

Solo en V_out=1d el lineal queda 0.8% por detrás. Al subir V_in el lineal degrada; la NN permanece estable.

4. NN mejora al naive a partir de V_out ≥ 5d

Naive predice el último retorno conocido — bueno en 1d, malo a largo plazo.

TABLA 1 — RESUMEN POR HORIZONTE: NN · NAIVE · LINEAL (V_IN=30)

HORIZONTE	MAE NN	MAE NAIVE	MAE LINEAL (V_IN=30)	NN VS NAIVE	NN VS LINEAL
V_out = 1d	0.0123	0.0178	0.0130	-31 %	-5.4 %
V_out = 5d	0.0056	0.0137	0.0059	-59 %	-5.1 %
V_out = 30d	0.0023	0.0125	0.0024	-82 %	-4.2 %
V_out = 90d	0.0013	0.0122	0.0014	-89 %	-7.1 %

★ Mejor lineal (V_in=5 · 2 668 params): MAE 0.0124 / 0.0056 / 0.0023 / 0.0013 — idéntico a NN en 3/4 horizontes. El lineal degrada con V_in mayor; la NN es invariante.

POR QUÉ ESTO ES CORRECTO — EMH + MAE

Los log-retornos del SP500 son **ruido blanco** (autocorrelación ≈ 0, test Ljung-Box no significativo). Bajo esa hipótesis, el estimador que minimiza el MAE es la media incondicional ≈ 0 — que es exactamente lo que aprenden todas las redes. *No es un fracaso del modelo: es la respuesta estadísticamente correcta al operar bajo la hipótesis de mercados eficientes.*

Reflexión sobre Modelos — 16 Arquitecturas

V_in = 30 días · Familias: Baseline, MLP, RNN, Conv1D, Mixtos

FIG. 3 — MAE TEST POR ARQUITECTURA · V_OUT=1D · V_IN=30D




Fig. 3. Las tres lineal desglosados por V_in ilustran la degradación con ventana mayor; todas las NN convergen al mismo MAE independientemente de la arquitectura.

TABLA 2 — COMPARATIVA DE MODELOS · NN EN V_IN=30 · LINEAL EN V_IN=5, 30 Y 90					
MODELO	FAMILIA	MAE 1D	MAE 5D	MAE 30D	MAE 90D
naive	Baseline	0.0178	0.0137	0.0125	0.0122
lineal (V_in=5)	Baseline	0.0124	0.0056	0.0023	0.0013
lineal (V_in=30)	Baseline	0.0130	0.0059	0.0024	0.0014
lineal (V_in=90)	Baseline	0.0143	0.0065	0.0027	0.0015
mlp_s	MLP	0.0123	0.0056	0.0023	0.0013
simple_rnn	RNN	0.0124	0.0056	0.0024	0.0013
gru	RNN	0.0124	0.0056	0.0024	0.0013
lstm	RNN	0.0124	0.0056	0.0024	0.0013
lstm_stack	RNN	0.0123	0.0056	0.0024	0.0013
bi_gru	RNN	0.0124	0.0057	0.0024	0.0013
lstm_drop	RNN	0.0123	0.0056	0.0024	0.0013
conv_s	Conv1D	0.0123	0.0056	0.0023	0.0013
conv_lstm_ln	Mixto	0.0123	0.0056	0.0024	0.0013
conv_gru_bott.	Mixto	0.0123	0.0056	0.0023	0.0013
conv_bilstm	Mixto	0.0123	0.0056	0.0024	0.0013
conv2_lstm	Mixto	0.0123	0.0056	0.0024	0.0013
lstm_dense	Mixto	0.0123	0.0056	0.0023	0.0013
conv_dense	Mixto	0.0123	0.0056	0.0023	0.0013

TABLA 3 — MEJOR ARQUITECTURA POR CRITERIO		
CRITERIO	MODELO	PARAMS
Mínimos params	simple_rnn	2 551
Mejor ratio	conv_dense	10 135
Con regularización	lstm_drop	24 023
Referencia sin NN	lineal (V_in=5)	2 668

Lineal(V_in=5) iguala el MAE de cualquier NN en 3/4 horizontes con una fracción de los parámetros.

CONCLUSIÓN DE DISEÑO

Añadir profundidad, regularización o datos de entrada no resuelve el problema porque **no hay señal que aprender** en los retornos pasados bajo EMH.

El único camino real es cambiar *qué información entra al modelo* (log-precio fraccional en vez de retornos) o *el objetivo de la tarea* (clasificar dirección en vez de regresar nivel).

Preprocesado Avanzado — Diferenciación Fraccional (FFD)

Marcos López de Prado · LSTM(64) de referencia · 5 técnicas + barrido de d · V_in=30

QUÉ ES FFD

Técnica de M. López de Prado (*Advances in Financial ML*, cap. 5). Aplica una diferenciación de orden *d* fraccionario sobre el **log-precio**, con pesos que decaen como $w_k \propto (-1)^k \cdot \Gamma(d+1)/(k! \cdot \Gamma(d-k+1))$, truncados cuando $|w_k| < 1e-5$. A diferencia de los retornos (d=1, sin memoria) o el precio (d=0, no estacionario), **d ≈ 0.2** preserva autocorrelación a largo plazo mientras mantiene la serie estacionaria. La hipótesis: el log-precio fraccional tiene estructura explotable que los retornos puros destruyen.

FIG. 4 — TÉCNICAS DE PREPROCESADO · V_IN=30 · V_OUT=1D




FIG. 5 — BARRIDO DE D · EXT. A · V_IN=30 · V_OUT=1D





TABLA 4 — RESUMEN GLOBAL · V_IN=30 · TODAS LAS VARIANTES

TÉCNICA	MAE V_OUT=1D	Δ CRUDO 1D	MAE V_OUT=30D	Δ CRUDO 30D
Crudo (baseline)	0.0123	—	0.0024	—
StandardScaler	0.0128	+4.1 % ✗	0.0026	+8.3 % ✗
Rolling Z-score	0.0126	+2.4 % ✗	0.0026	+8.3 % ✗
FFD (d=0.4)	0.0114	-7.3 % ✓	0.0025	+4.2 %
Feature Engineering	0.0125	+1.6 % ✗	0.0026	+8.3 % ✗
FFD (d=0.2) — Ext. A	0.0112	-8.9 % ✓	—	—
FFD (d=0.2) — Ext. B V_out=30d	0.0112	-8.9 % ✓	0.0035	+45.8 % ✗
Multi-rama — Ext. C	0.0124	+0.8 % ✗	0.0025	+4.2 %
FFD + feat — Ext. D	0.0115	-6.5 % ✓	0.0024	0.0 %

FIG. 6 — FFD(D=0.2) EN TODOS LOS HORIZONTES · EXTENSIÓN B · V_IN=30



CONCLUSIÓN DE PREPROCESADO

El preprocesado óptimo depende del horizonte: **FFD(d=0.2)** para **V_out=1d** y **retornos crudos** para **V_out ≥ 5d**. El cuello de botella no es la arquitectura ni el preprocesado — es la señal disponible.

Carteras 2025 — Resultados Reales

MLP Dense(64) · V_in=10 · V_out=90 · rebalanceo del modelo cada 90 días · rebalanceo correctivo cada 21 días · 249 días de trading

FIG. 7 — RETORNO ACUMULADO · ENE 2025 – DIC 2025 · 249 DÍAS DE TRADING




Fig. 7. Ambas carteras con trayectoria similar. Corrección pronunciada en Abr-25 (MaxDD ~-10.85%), recuperación sostenida desde May-25. La diferencia NN vs BH es marginal (+0.14 pp) durante todo el período.

TABLA 5 — MÉTRICAS DE PORTFOLIO · DATOS REALES · RF = 0

CARTERA	RET. TOTAL	RET. ANUAL	VOLATILIDAD	SHARPE	SORTINO	MAX DD
Cartera NN	+16.96 %	+17.18 %	13.26 %	1.296	1.588	-10.75 %
Buy & Hold (1/23)	+16.82 %	+17.04 %	13.22 %	1.289	1.566	-10.85 %

Período: 1 ene 2025 – 31 dic 2025 (249 días de trading). Métricas anualizadas con 252 días/año.

HALLAZGO — CARTERA NN EFECTIVAMENTE LONG-ONLY · PREDICCIONES IDÉNTICAS EN LOS 3 REBALANCEOS

El modelo predice **retornos positivos para los 23 activos** en los tres rebalanceos (2025-01-03, 2025-05-15, 2025-09-24) con **exactamente los mismos valores**: rango IP +0.00029 (peso 2.54%) → KR +0.00077 (peso 6.84%). La repetición confirma el colapso a la media: el modelo no distingue el contexto de mercado entre períodos.

La Cartera NN no es long/short como se esperaba, sino **long-only con pesos distintos al uniforme**. La diferencia marginal (+0.14 pp retorno total, Sharpe +0.007) se debe exclusivamente a las *ponderaciones*, no a la dirección de las apuestas. El mismo colapso al predictor de la media observado en el MAE se refleja aquí como colapso a la cartera uniforme.

METODOLOGÍA EJECUTADA

1. **Modelo: MLP Dense(64, L2=1e-4) → Dense(23)**
V_in=10, V_out=90, lr=1e-4, 300 épocas, batch=64. Entrenado sobre histórico 1945–2024 (15 857 días).
2. **Rebalanceo del modelo cada 90 días (3 rebalanceos en 2025)**
Fechas: 2025-01-03, 2025-05-15, 2025-09-24. En cada fecha se usa la ventana de V_in=10 días más reciente para generar nuevas predicciones. El modelo **no se re-entrena** — solo se usa para inferencia con datos actualizados.
3. **Cartera NN: $w_i = y_pred_i / \sum |y_pred_i|$ · rebalanceo correctivo cada 21 días**
Todos positivos → long-only. Mayor peso a KR (6.84%), MO (6.35%), MSI (5.18%); menor a IP (2.54%). Dentro de cada período de 90 días, rebalanceo cada 21 días bursátiles para corregir la deriva natural de pesos.
4. **Cartera Buy & Hold: $w_i = 1/23 \approx 4.35\%$ — sin rebalanceo**
Pesos equiponderados al inicio, luego se dejan derivar libremente según el comportamiento relativo de cada activo. Benchmark pasivo de referencia.

Conclusiones

16 arquitecturas · 256 entrenamientos · tres hallazgos

TRES HALLAZGOS PRINCIPALES

1.

El colapso al predictor de la media es la respuesta correcta, no un fallo

Bajo MAE y log-retornos eficientes (ruido blanco $\approx$ martingala), el estimador óptimo es la media incondicional ≈ 0 . Todas las arquitecturas lo descubren empíricamente. El techo no es del modelo — es del problema.
2.

La regresión lineal con 2 668 params iguala a cualquier red neuronal

SimpleRNN (2 551), BiLSTM+Conv (14 615), MLP (45 719) — todos obtienen el mismo MAE que `lineal(V_in=5)` en 3 de 4 horizontes. Más capacidad no compra señal cuando el input es ruido.
3.

FFD(d=0.2) rompe el techo en V_out=1d (−8.9%), pero empeora en V_out ≥ 30d (+45.8%)

La memoria fraccional solo es útil en el horizonte muy corto. El preprocesado óptimo depende del horizonte; la señal disponible es el verdadero cuello de botella.

TABLA 6 — ¿QUÉ HARÍAMOS DIFERENTE?

LIMITACIÓN ACTUAL	ALTERNATIVA
Regresión del nivel (MAE)	Clasificación de dirección $\uparrow/\downarrow$ Cross-entropy no colapsa a la media bajo EMH débil
Solo log-retornos	VIX + datos macro Features exógenos con autocorrelación real
Ventana fija V_in	Atención (Transformer) Aprender qué días del pasado importan
Retornos crudos para V_out=1d	FFD(d=0.2) solo para V_out=1d Única mejora real confirmada empíricamente

LECCIÓN CENTRAL DEL TALLER

Los 256 experimentos demuestran empíricamente lo que la hipótesis de mercados eficientes predice teóricamente: *no hay señal extraíble de los retornos pasados que permita superar la media de forma consistente.*

La única mejora real vino de cambiar **qué información entra al modelo** (FFD retiene memoria fraccional del log-precio), no de añadir más capas o parámetros.

El cuello de botella es siempre la señal — nunca la arquitectura.